Résidences Azur : appeler les bonnes réservations

Un séjour sur trois est annulé, souvent au dernier moment, et le logement reste vide. Notre modèle estime, dès l'enregistrement, la probabilité qu'une réservation soit annulée, et une application recommande d'appeler ou non le client.

0,18

seuil économique : appeler si p × ⅓ × 100 € > 6 €

0,60

AUPRC sur les réservations les plus récentes (hasard : 0,25)

+28 k€

de gain net sur 7 mois, par rapport à « appeler tout le monde »

Ilham KADRI · Romain LIÉNARD · Hajar MOUSSAOUI · Florent NGOR

Six colonnes « connaissent » déjà la réponse : on les retire

VARIABLE	PREUVE	DÉCISION
statut_dossier, date_statut	« Annulé » = 100 % d'annulation, « Séjour effectué » = 0 %	fuite, exclue
logement_attribue	attribué à l'arrivée : 4,5 % d'annulation s'il diffère de la demande, contre 37 %	fuite, exclue
nb_places_parking	0 % d'annulation dès qu'une place est demandée	fuite, exclue
nb_modifications, jours_attente	s'accumulent après l'enregistrement	inconnues, exclues
code_promo, indice_affinite	aucun lien : 31,5 à 35 % par code ; corrélation −0,007	inutiles, exclues
pays_client, demandes spéciales	très influentes, saisie à confirmer avec le métier	gardées, avec réserve

Le délai avant l'arrivée est le premier signal

Taux d'annulation selon le délai

≤ 7 jours	8 %
8 à 30 j	24 %
1 à 2 mois	33 %
2 à 4 mois	38 %
4 à 7 mois	41 %
> 7 mois	55 %

Autres constats

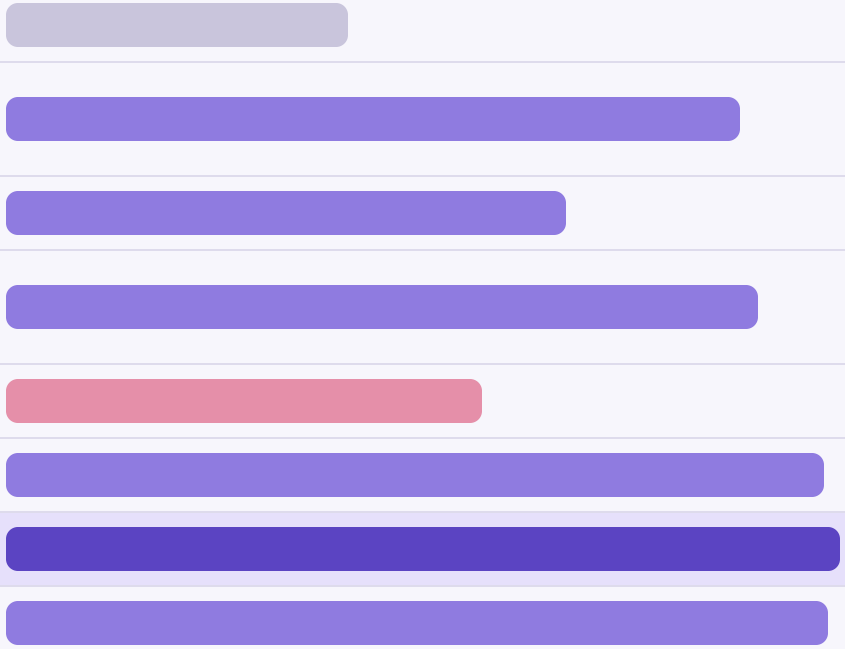
- **25 % de lignes identiques**, annulées à 53 % : supprimées avant le découpage
- Urbaine 37,5 % contre littoral 24 % ; Groupes 57 %, Direct 13 %
- Manquant d'agence ou d'entreprise = pas d'intermédiaire
- Tarifs aberrants (≤ 0, 6 372 €) ramenés dans [0 ; 1 000]

15 variables dérivées : délai, nuits, personnes, tarif par personne, historique, agence, mois et jour cycliques, saison.

Sans variables dérivées, l'AUPRC du boosting passe de 0,600 à 0,512

Le boosting l'emporte, l'arbre illimité apprend par cœur

MODÈLE	AUPRC TEST	AUPRC ENTRAÎNEMENT	TEMPS
Baseline	0,246	0,245	0 s
Logistique sans / avec dérivées	0,495 / 0,531	0,663	5 s
Arbre profondeur 3	0,404	0,455	1 s
Arbre profondeur 10 (validation)	0,540	0,735	2 s
Arbre illimité	0,342	**1,000**	2 s
Forêt aléatoire	0,588	0,906	16 s
Gradient boosting (retenu)	**0,600**	**0,822**	**11 s**
MLP 64×64 (bonus)	0,591	0,809	13 s



Testé sur l'avenir, le modèle double presque le gain

Protocole

- Doublons supprimés avant tout découpage
- Découpage **chronologique** : 80 % les plus anciennes / 20 % les plus récentes
- Réglages sur une validation, test utilisé une fois
- Validation croisée temporelle : 0,622 ± 0,074
- Diagnostic : la validation plafonne vers 0,67, écart stable ≈ 0,17

Gain net sur 16 797 réservations de test

Appeler tout le monde	36 785 €
Modèle, seuil 0,18	**64 519 €**
Modèle, seuil validé 0,11	**70 657 €**

Au seuil 0,18 : précision 0,50, rappel 0,73. Le modèle sous-estime le risque récent : on recommande 0,11.

Seuil théorique 0,18 = 6 € / (⅓ × 100 €)

Ce qui fait annuler, et l'outil pour agir

Variables les plus influentes (permutation)

- Pays du client et agence vendeuse
- Demandes spéciales : un client engagé annule peu
- Dates : délai et saison
- Historique du client, origine, garantie

« Réservation lointaine, agence en ligne, sans demande spéciale, client inconnu : à appeler en priorité. »

Démonstration

- **python app.py** : 10 champs, probabilité, recommandation, curseur de seuil, saisies impossibles refusées
- **uvicorn api:api** : POST /predict, schéma validé, 422 si invalide
- **pytest** : 11 tests
- Les deux chargent le même **model.pkl** (pipeline entier)

Ce qu'il faut vérifier avant la mise en service

Limites

- Pays et demandes spéciales : saisis à la réservation ? À confirmer
- Dérive : le taux d'annulation change selon la période
- Probabilités mal calibrées sur les données récentes
- Équité : le pays pèse fort, un humain garde la décision

Suite

- Calibrer les probabilités, surveiller la dérive (PSI)
- Ré-entraîner chaque trimestre
- Saisir l'historique du client
- Mise en ligne sur Hugging Face Spaces